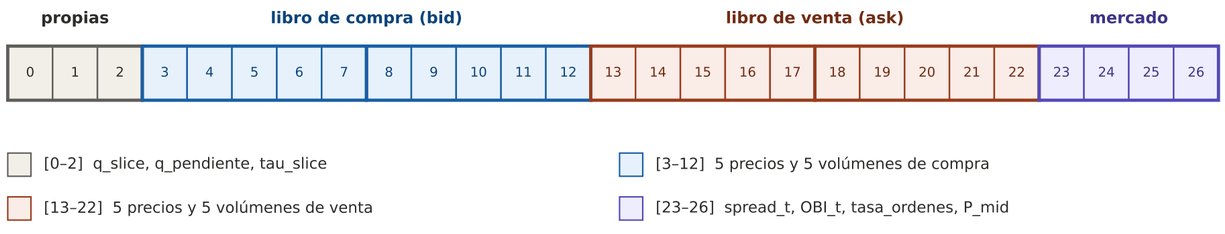
Figura 3. Espacios de estado, acción y recompensa de los dos niveles de agentes

Qué ve cada agente, qué puede decidir y cómo se le premia; el color indica el origen de cada dato

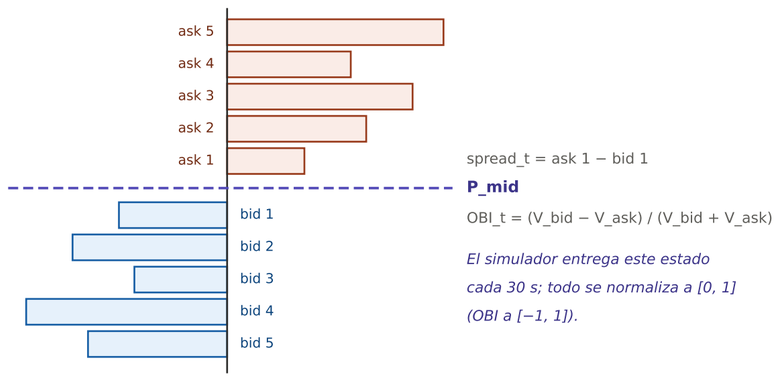
(a) Estado del Maestro S_M: 7 variables

#	Variable	Rango	Origen	Definición
0	**q_t**	[0, 1]	**interno**	Fracción pendiente: (Q_total − Q_ejec) / Q_total
1	**τ_t**	[0, 1]	**hora**	Hora del día: (t − 09:30) / 390 min
2	**n_slices**	[0, 1]	**interno**	Decisiones ya tomadas / 13
3	**volatilidad**	[0, 1]	**yfinance (real)**	Desviación móvil (6 velas) del cierre, MinMax
4	**vol_promedio**	[0, 1]	**yfinance (real)**	Media móvil (6 velas) del volumen, MinMax
5	**OBI_agregado**	[−1, 1]	**simulador**	(V_bid − V_ask) / (V_bid + V_ask); hoy vale 0 (pendiente)
6	**sesión**	{0; 0,5; 1}	**hora**	Apertura, media jornada o cierre (corte a las 11:00 y 14:00)

(b) Estado del Ejecutor S_E: 27 variables



Libro de órdenes: 5 niveles por lado (esquema ilustrativo, volúmenes no a escala)



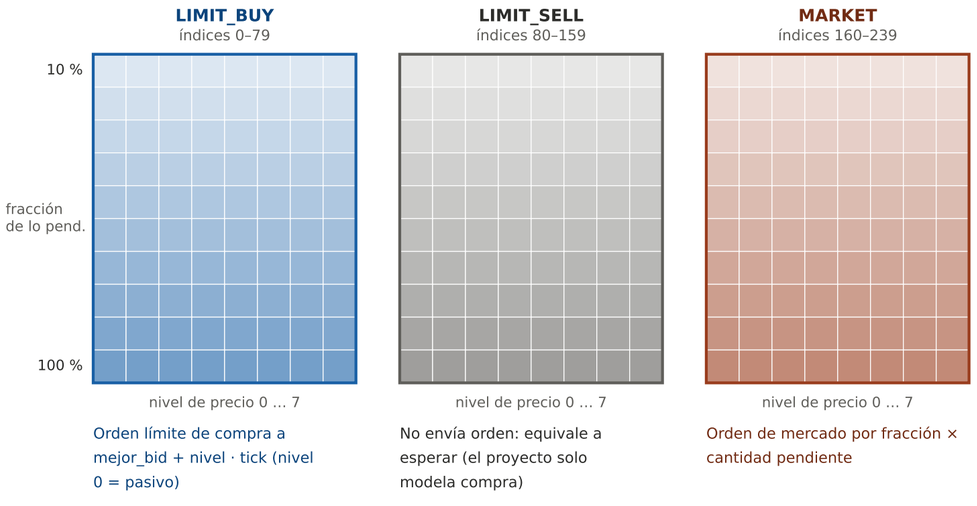
(c) Acción del Maestro A_M: 40

α \ ventana v (min)	1	5	10	15
5 %	0	1	2	3
10 %	4	5	6	7
15 %	8	9	10	11
20 %	12	13	14	15
25 %	16	17	18	19
30 %	20	21	22	23
35 %	24	25	26	27
40 %	28	29	30	31
45 %	32	33	34	35
50 %	36	37	38	39

α: fracción de lo pendiente que se asigna

Índice plano = 4 · i_α + i_v (0 … 39)

(d) Acción del Ejecutor A_E: 240 = 3 × 10 × 8



Índice plano = 80 · tipo + 8 · fracción + nivel; la red del Ejecutor tiene 240 salidas (una por combinación)

(e) Recompensas

R_M del Maestro (terminal)

- R_M = −IS_total − λ · máx(0, Q_pend) · P_mid,cierre
- IS_total = (P̄_ejec − P_ref) · Q_total
- λ = 0,05 (provisional): castiga lo no ejecutado
- Solo se entrega al cierre de la jornada

R_E del Ejecutor (densa, cada 30 s)

- R_E = (P_mid − P_ejec) · q_ejec − β · σ² · q_ejec
- 1.er término: ahorro frente al precio medio
- 2.º término: riesgo; σ² con ventana móvil de 20 pasos (10 min)
- β = 0,0061796 (0,1 · β∗, provisional)
- Escala: pesos por acción del tramo asignado

Variante en estudio (decisión D3)

- Riesgo sobre lo pendiente: −β · σ² · Q_pend
- Evita que «esperar» salga gratis
- Rige la opción 0 con vigilancia: cumplimiento ≥ 95 %

Origen del dato: yfinance (real) · simulador · interno · hora

Todas las variables de S_M y S_E se normalizan a [0, 1] (OBI a [−1, 1]) según los esquemas SM_schema.json y SE_schema.json. A_E es la versión discretizada del Título I (que usaba volumen continuo y 4 niveles de precio).